

异常检测算法系统性对比研究 —— 团队分工文档

课程：数据挖掘

小组成员：[姓名1-学号1] / [姓名2-学号2] / [姓名3-学号3] / [姓名4-学号4]

项目周期：2026 年 5 月 26 日 ~ 6 月 16 日（3 周）

选题背景

研究背景

异常检测（Anomaly Detection）旨在识别数据中显著偏离常态分布的样本，广泛应用于网络入侵检测、金融欺诈识别、工业质量控制、医疗诊断等场景。该问题面临以下核心挑战：

- 标签稀缺**：真实场景中异常样本极少，难以采用传统监督学习
- 类别极度不平衡**：典型场景下异常占比 0.1%~5%
- 异常模式多样**：点异常、上下文异常、群体异常并存
- 数据形态多样**：表格、时序、图像、图结构、文本均有需求

现存问题

- 多数论文只在自己选定的 1~2 个数据集上对比，结论可推广性差
- 评估指标不统一，AUC-ROC 在极度不平衡场景下虚高
- 训练集“污染”（混入异常样本）这一真实问题，缺乏系统性鲁棒性分析
- 深度方法是否真的优于经典方法，存在争议（参考 ADBench, NeurIPS 2022）

项目目标

在统一实验框架下，横跨 5 类数据形态（表格 / CV / NLP / 时序 / 图），系统对比 6 大类异常检测算法，以**训练集污染率鲁棒性**为核心研究问题，结合实验验证，给出“何时该用哪类算法”的结论，并以 Streamlit 交互界面展示成果。

数据来源

本项目采用 3 个学界公认的权威 benchmark，覆盖 5 类数据形态，共计 **29 个数据集**。

ADBench（表格 + CV + NLP）

- 来源**：Han et al., NeurIPS 2022
- GitHub**：<https://github.com/Minqi824/ADBench>
- 内容**：57 个数据集，分为 Classical（表格 47 个）、CV（5 个，ResNet-18 特征 512 维）、NLP（5 个，BERT embedding 768 维）；CV/NLP 数据集每个会按“以某一类为正常类”的设定派生出多个 setting（如 CIFAR10_0~9）
- 数据格式**：npz 文件，包含 X（特征矩阵）和 y（标签，0=正常，1=异常）
- 本地位置**：ADBench-main/adbench/datasets/

计划使用子集（9 个表格 + 4 个 CV + 4 个 NLP = 17 个）：

表格（9 个）：

数据集	样本数	维度	异常率	领域
Cardio	1,831	21	9.6%	医疗
Thyroid	3,772	6	2.5%	医疗
Satellite	6,435	36	31.6%	遥感
Shuttle	49,097	9	7.2%	工业
Credit Card	284,807	30	0.17%	金融
Pima	768	8	35%	医疗

数据集	样本数	维度	异常率	领域
Annthroid	7,200	6	7.4%	医疗
Mammography	11,183	6	2.3%	医疗
Pendigits	6,870	16	2.3%	数字识别

CV (4 个): CIFAR10_0、CIFAR10_1、FashionMNIST_0、FashionMNIST_1 (每个 ~5000 样本 × 512 维)

NLP (4 个): 20news_0、20news_1、agnews_0、amazon (每个 200010000 样本 × 768 维)

TSB-AD (时序)

- 来源: Liu et al., NeurIPS 2024
- GitHub: <https://github.com/TheDatumOrg/TSB-AD>
- 内容: 1,070 条单变量 + 350 条多变量时序, 覆盖 40 个领域
- 数据格式: csv 文件, 列为 Data (数值) + Label (0/1); 文件名含 tr_ 索引标记训练截止点
- 本地位置: TSB-AD-main/Datasets/
- 完整数据下载: <https://www.thedatum.org/datasets/TSB-AD-U.zip>
- 计划使用: 按领域分层抽样 8 条代表性时序 (Facility/Medical/Sensor/Web/Finance/Traffic 等领域各 1~2 条), 选择结果记录在 data/timeseries/selected_files.txt 中保证可复现

GADBench (图)

- 来源: Tang et al., NeurIPS 2023
- GitHub: <https://github.com/squareRoot3/GADBench>
- 内容: 10 个真实图数据集, 节点数从千级到 6M 级
- 数据格式: DGL 二进制文件, 包含节点特征、邻接矩阵、标签、预设 train/val/test mask
- 本地位置: GADBench-master/datasets/
- 数据下载: <https://drive.google.com/file/d/1txzXrzwBBAOEATXmfKzMUUKaXh6PJeR1>

计划使用子集 (4 个):

数据集	节点数	边数	异常率	类型
T-Finance	39,357	21M	4.6%	金融交易图
Reddit	10,984	168K	3.3%	用户-帖子图
Amazon	11,944	4.4M	6.9%	电商评论图
Weibo	8,405	408K	10.3%	社交网络

三个实验

实验	目的	做法
Exp-1 基准对比	各算法在各数据集上的性能	27 个算法 × 29 个数据集, 记录 AUC-ROC / AUC-PR / F1
Exp-2 污染率实验	训练集被污染时算法性能退化程度	控制训练集中异常保留比例为 0%/1%/5%/10%/20%, 覆盖表格 / 时序 / 图三类形态, 观察 AUC 变化
Exp-3 跨模态对比	通用算法在不同数据形态上的排名差异	通用算法在表格/CV/NLP/时序/图上跑, 对比排名

算法列表（27 个，暂定，根据运行时间调整）

无监督（15 个）

#	算法	类别	出处	年份	形态专属	库
1	IQR	统计	Tukey 教材	1977	—	自己写
2	LOF	近邻密度	SIGMOD	2000	—	PyOD
3	KNN-AD	近邻距离	SIGMOD	2000	—	PyOD
4	Isolation Forest	树集成	ICDM	2008	—	PyOD
5	ECOD	浅层集成	TKDE	2022	—	PyOD
6	COPOD	浅层集成	ICDM	2020	—	PyOD
7	AutoEncoder	深度重构	Science	2006	—	PyOD
8	Deep SVDD	深度边界	ICML	2018	—	PyOD
9	ARIMA	传统统计时序	Box-Jenkins	1970	时序	statsmodels
10	Prophet	加法回归时序	Facebook	2017	时序	prophet
11	LSTM-AE	深度时序重构	ICML Workshop	2016	时序	PyTorch
12	MatrixProfile	时序模式匹配	ICDM	2016	时序	stumpy
13	DOMINANT	图 GNN 重构	SDM	2019	图	PyGOD
14	CoLA	图对比学习	TNNLS	2021	图	PyGOD
15	DADA	时序基础模型（自适应瓶颈+双对抗解码）	ICLR	2025	时序	iambowen 仓库

有监督（12 个）

#	算法	类别	出处	年份	形态专属	库
16	Logistic Regression	线性	经典	1958	—	sklearn
17	Random Forest	树集成	ML 期刊	2001	—	sklearn
18	XGBoost	Boosting	KDD	2016	—	xgboost
19	LightGBM	Boosting	NeurIPS	2017	—	lightgbm
20	MLP	深度分类	Nature	1986	—	sklearn
21	TabPFN	表格基础模型	Nature	2025	—	tabpfn
22	LSTM	时序循环	Neural Comp.	1997	时序	PyTorch
23	MiniRocket	时序卷积核	KDD	2021	时序	sktime
24	GCN	图卷积	ICLR	2017	图	GADBench
25	BWGNN	图谱方法	ICML	2022	图	GADBench
26	XGBGraph	树+图聚合	NeurIPS	2023	图	GADBench
27	UNPrompt	图零样本提示	IJCAI	2025	图	mala-lab 官方

一、角色分工总览

角色	负责人	职责范围	可考核输出
数据工程负责人	[姓名 A]	数据获取、清洗、融合、特征工程、数据管道构建	数据预处理代码、特征文档、数据血缘图
算法负责人（建模）	[姓名 B]	核心算法实现/调优、对比实验设计、超参数优化	模型训练代码、实验记录表、模型对比分析

角色	负责人	职责范围	可考核输出
评估与分析负责人	[姓名 C]	评估指标设计、统计显著性检验、结果可视化、错误分析	评估代码、可视化图表、分析报告章节
工程与交付负责人	[姓名 D]	代码整合、Pipeline 构建、交互界面/报告生成、版本管理	可运行完整代码、README、答辩 PPT

二、详细职责与产出

数据工程负责人 [姓名 A]

数据来源：

- ADBench： <https://github.com/Minqi824/ADBench>
- TSB-AD： <https://github.com/TheDatumOrg/TSB-AD> （完整数据：<https://www.thedatum.org/datasets/TSB-AD-U.zip>）
- GADBench： <https://github.com/squareRoot3/GADBench> （数据：<https://drive.google.com/file/d/1txzXrzwBBAOEATXmfKzMUUKaXh6PJeR1>）

类别	具体任务
ADBench 加载与预处理	加载 Classical（表格 47 个）+ CV + NLP 的 npz 文件；统一转 float64；对未标准化的数据集做 StandardScaler（cover 等 int 型数据范围 -173~7173 需标准化，fraud 已归一化可跳过）；实现分层 train_test_split
TSB-AD 时序处理	下载完整数据集；解析文件名中 tr_ 索引确定训练/测试截止点；用训练段统计量做 z-score 归一化；实现滑窗切分（window_size / stride 可配置）；窗口标签对齐
GADBench 图加载	用 DGL load_graphs 加载二进制图文件；提取节点特征、标签、预设 train/val/test mask；对节点特征做 StandardScaler
污染率注入器	实现两种污染方式：①无监督污染（控制训练集中异常样本的保留比例，0%=纯净/5%/10%/20%）②有监督污染（标签 双向对称 翻转，随机将 5%/10%/20% 的样本标签 0↔1 互换）。两种方式分别用于无监督算法和有监督算法的 Exp-2 实验，固定 seed 保证可复现
统一加载接口	封装统一函数，输入数据集名称返回标准格式 (X_train, X_test, y_train, y_test)，屏蔽底层形态差异
EDA 报告	统计每个数据集的样本数、维度、异常率、值范围、dtype、是否需要标准化，输出为 JSON/CSV 供前端 Streamlit 使用（同时体现在报告第 3 章）
数据血缘文档	记录每个数据集的来源、文件格式、处理步骤（体现在报告第 3 章）
答辩讲解	负责 10 分钟答辩的全程讲解（需提前熟悉全部实验结果和算法逻辑）

产出文件：

输出	路径
ADBench 适配器	adapters/adbench_adapter.py
时序适配器	adapters/timeseries_adapter.py
图适配器	adapters/graph_adapter.py
污染率注入器	data/contaminate.py
EDA 统计文件	data/eda_summary.json

报告章节：第 3 章「数据集与预处理」主笔

算法负责人（建模） [姓名 B]

类别	具体任务
统一接口设计	设计 BaseDetector 抽象基类，定义 fit() / decision_function() / predict() 接口
统计方法（自己写）	IQR（四分位距异常分数）
无监督通用（PyOD 调用）	LOF、KNN-AD、Isolation Forest、ECOD、COPOD、AutoEncoder、Deep SVDD

类别	具体任务
有监督通用 (sklearn/xgboost/lightgbm/tabpfn 调用)	LR、RF、XGBoost、LightGBM、MLP、TabPFN（Nature 2025，表格基础模型，仅在样本≤10000 的数据集上推理，超出限制的数据集直接跳过）
时序专属（无监督）	ARIMA（statsmodels 调用，残差异常检测）、Prophet（prophet 调用，残差异常检测）、LSTM-AE（PyTorch 实现）、MatrixProfile（stumpy 调用）、DADA（ICLR 2025，iambowen 仓库，时序基础模型，zero-shot 推理）
时序专属（有监督）	LSTM（PyTorch 实现）、MiniRocket（sktime 调用）
图专属（无监督）	DOMINANT、CoLA（PyGOD 调用）
图专属（有监督）	GCN、BWGNN、XGBGraph（GADBench 代码调用）、UNPrompt（IJCAI 2025，mala-lab 仓库）
评估指标实现	编写 eval/metrics.py（AUC-ROC、AUC-PR、F1@best），在实验脚本中调用
Exp-1 基准对比	27 算法 × 29 数据集，默认超参，记录所有指标 + 耗时
Exp-2 污染率实验	通用算法 × 表格/时序/图数据集 × 5 档污染率，记录 AUC 退化
Exp-3 跨模态对比	通用算法在 5 类形态上跑，记录排名
实验记录	所有结果自动写入 experiment_log.csv

产出文件：

输出	路径
算法基类	models/base.py
评估指标	eval/metrics.py
统计方法	models/statistical.py
无监督通用	models/lof.py 、 models/knn.py 、 models/iforest.py 、 models/ecod_copod.py 、 models/autoencoder.py 、 models/deep_svdd.py
有监督通用	models/supervised.py（LR/RF/XGBoost/LightGBM/MLP/TabPFN 统一封装）
时序专属	models/timeseries/arma.py 、 models/timeseries/prophet.py 、 models/timeseries/lstm_ae.py 、 models/timeseries/lstm_supervised.p
图专属	models/graph/dominant.py 、 models/graph/cola.py 、 models/graph/gnn_supervised.py（GCN/BWGNN/XGBGraph 统一封装）、models
实验脚本	experiments/exp1_baseline.py 、 experiments/exp2_contamination.py 、 experiments/exp3_cross_modal.py
实验记录表	results/experiment_log.csv

报告章节：第 4 章「方法 / 算法实现」主笔

评估与分析负责人 [姓名 C]

类别	具体任务
Exp-1 结果分析	从 experiment_log.csv 读取基准实验结果；绘制算法×数据集性能热力图（颜色=AUC）；绘制算法平均排名柱状图；选 2~3 个代表性数据集绘制 ROC 曲线叠加图；绘制性能-效率权衡图（x=运行时间/参数量，y=AUC，每个点一个算法，气泡大小=参数量）
Exp-2 结果分析	绘制污染率退化曲线（x=污染率 0%/5%/10%/20%，y=AUC，每条线一个算法）；制作鲁棒性排名表（按 AUC 下降幅度排序）；绘制污染率×形态交叉分析图（同一算法在不同形态上的退化对比）
Exp-3 结果分析	绘制算法×形态热力图（通用算法在 5 类形态上的 AUC）；绘制雷达图（每个算法 5 个轴=5 种形态，面积=全能性）；绘制形态难度柱状图（所有算法在每种形态上的平均 AUC）
错误分析	选 1~2 个数据集，绘制正常/异常样本的异常分数分布直方图（看分离度）；挑 3~5 个典型 FN（漏检）和 FP（误报）案例，分析算法判断错误的原因
统计显著性检验 (可选加分)	用 Friedman 检验判断算法间排名差异是否显著；用 Nemenyi post-hoc 画 Critical Difference 图，标明哪些算法之间有/无显著差异

产出文件：

输出	路径
可视化代码	eval/visualize.py
统计检验代码（可选）	eval/significance.py
Exp-1 图表	figures/exp1/（热力图、排名柱状图、ROC 曲线、时间对比）
Exp-2 图表	figures/exp2/（退化曲线、鲁棒性排名表、形态交叉图）
Exp-3 图表	figures/exp3/（跨模态热力图、雷达图、形态难度图）
错误分析图表	figures/error_analysis/（分数分布图、案例分析）

报告章节：第 2 章「相关工作」+ 第 5 章「实验结果」+ 第 6 章「讨论与理论分析」主笔

工程与交付负责人 [姓名 D]

类别	具体任务
Streamlit 界面 - 数据集浏览页	用户选择数据集名称，展示该数据集的基本信息（样本数、维度、异常率）和特征分布图
Streamlit 界面 - 基准对比页	用户选择数据集，展示所有算法在该数据集上的 AUC-ROC / AUC-PR 柱状图 + ROC 曲线叠加
Streamlit 界面 - 污染率分析页	用户通过滑块选择污染率（0%~20%），实时展示各算法的 AUC 退化曲线
Streamlit 界面 - 跨模态对比页	展示通用算法在 5 类形态上的热力图和雷达图
一键运行脚本	编写 run_all.py，按顺序调用数据加载 → 算法训练 → 指标计算 → 结果存 CSV，支持命令行参数选择跑哪个实验
答辩 PPT	制作 10 分钟答辩用 PPT，包含项目背景、方法、关键实验结果图、结论

产出文件：

输出	路径
交互界面	app/streamlit_app.py
一键运行脚本	run_all.py
依赖管理	requirements.txt
README	README.md
答辩 PPT	demo/slides.pdf

报告章节：摘要 + 第 1 章「引言」+ 第 7 章「结论」+ 参考文献/附录 主笔；负责最终合稿

三、详细时间表（按成员 × 日期）

项目周期：2026 年 5 月 26 日 ~ 6 月 16 日（3 周）

第 1 周：5/26 ~ 6/1（框架搭建 + Exp-1）

日期	A（数据工程）	B（算法建模）	C（评估分析）	D（工程交付）
5/26~5/28	数据加载与预处理	统一基类 + 统计/近邻/树/边界/集成算法封装	—	—
5/29~6/1	—	深度算法 + 形态专属算法 + eval/metrics.py + Exp-1 全部跑完	—	—

第 2 周：6/2 ~ 6/8（Exp-2 + Exp-3 + 可视化 + 界面）

日期	A（数据工程）	B（算法建模）	C（评估分析）	D（工程交付）
6/2~6/5	—	Exp-2 污染率 + Exp-3 跨模态实验跑完	Exp-1 图表（热力图、性能-效率权衡图、ROC 曲线）	Streamlit 界面开发

日期	A（数据工程）	B（算法建模）	C（评估分析）	D（工程交付）
6/6~6/8	—	—	Exp-2 + Exp-3 图表（退化曲线、雷达图、形态热力图）+ 错误分析	Streamlit 最终版

第 3 周：6/9 ~ 6/16（报告 + 答辩）

日期	A（数据工程）	B（算法建模）	C（评估分析）	D（工程交付）
6/9~6/12	报告第 3 章	报告第 4 章	报告第 5、6 章	报告第 1、7 章
6/13~6/16	答辩准备	—	—	PPT

关键节点

- 6 月 1 日：数据 pipeline 跑通 + Exp-1 全部跑完
- 6 月 8 日：全部实验完成 + Streamlit 可演示
- 6 月 12 日：报告初稿完成
- 6 月 16 日：终稿提交 + 答辩

四、报告章节分配

报告章节	主笔
摘要	D
1. 引言	D
2. 相关工作	C
3. 数据集与预处理	A
4. 方法	B
5. 实验结果	C
6. 讨论	C
7. 结论	D
参考文献 / 附录	D

五、仓库目录结构

```
final_project/
├─ README.md
├─ requirements.txt
├─ run_all.py
├─ data/
│   ├── contaminate.py
│   ├── eda_summary.json
│   ├── tabular/
│   ├── cv/
│   ├── nlp/
│   ├── timeseries/
│   └─ graph/
├─ adapters/
│   ├── adbench_adapter.py
│   ├── timeseries_adapter.py
│   └─ graph_adapter.py
├─ models/
│   ├── base.py
│   ├── statistical.py
│   ├── lof.py
│   ├── knn.py
│   ├── iforest.py
│   ├── ecod_copod.py
│   ├── autoencoder.py
│   ├── deep_svdd.py
│   ├── supervised.py
│   ├── timeseries/
│   │   ├── arima.py
│   │   ├── prophet.py
│   │   ├── lstm_ae.py
│   │   ├── lstm_supervised.py
│   │   └─ dada.py
│   └─ graph/
│       ├── dominant.py
│       ├── cola.py
│       ├── gnn_supervised.py
│       └─ unprompt.py
├─ eval/
│   ├── metrics.py
│   ├── visualize.py
│   └─ significance.py
├─ experiments/
│   ├── exp1_baseline.py
│   ├── exp2_contamination.py
│   └─ exp3_cross_modal.py
├─ app/
│   └─ streamlit_app.py
├─ results/
│   └─ experiment_log.csv
├─ figures/
│   ├── exp1/
│   ├── exp2/
│   ├── exp3/
│   └─ error_analysis/
├─ demo/
│   └─ slides.pdf
└─ report/
    ├── main.tex
    ├── refs.bib
    └─ sections/
```


六、commit 规范

- **feat**: 添加 IsolationForest 封装
- **fix**: 修复 Cardio 数据加载维度对齐错误
- **exp**: 完成 Exp-2 污染率实验
- **docs**: 更新 README
- **refactor**: 重构评估指标接口