

跨模态抗污染异常检测的统一基准评测与主动去噪防御研究

杨景翔 (2351576) 徐云鹏 (2353583) 陈艺龙 (2352359) 李雪菲 (2354093)

摘要: 异常检测旨在从高维数据中识别偏离正常分布的稀有样本,是数据挖掘与智能诊断系统的关键环节。然而现有评测体系普遍存在两点局限:一是评测口径碎片化,表格、时序、图、图像与文本各模态的基准相互割裂,难以在统一标准下横向比较;二是对标签污染缺乏系统刻画,而真实标注中的标签噪声会显著破坏监督模型的决策边界。针对上述问题,本文构建了一个跨越五大模态的统一抗污染异常检测基准平台,在 29 个真实数据集上系统评测了 26 种经典与前沿算法,并设计了一套即插即用的主动去噪防御包装器。我们通过四组递进实验,依次刻画了算法在无噪状态下的性能上限 (Exp1)、在 0%–20% 对称标签翻转下的退化轨迹 (Exp2)、跨模态的相对分类难度 (Exp3),以及主动防御在 20% 重度污染下的去噪挽救能力与失效边界 (Exp4)。实验表明:以四分位距统计为清洁剂、以样本剪裁为策略的 IQR_Trim 防御对高容量监督模型保护效果最佳,使多层感知机的 AUC-ROC 绝对回升 2.52 个百分点,且剪裁策略在各类清洁剂上均稳定优于标签纠正策略;与此同时,该防御对线性逻辑回归与表格基础模型 TabPFN 产生轻微负迁移,从经验上印证了去噪鲁棒学习中的“没有免费的午餐”原则。本研究为跨模态异常检测的鲁棒性评估提供了统一底座,并为工业级抗污染系统的部署给出了可操作的策略依据。

关键词: 异常检测; 跨模态基准; 标签污染; 鲁棒学习; 主动去噪防御; 失效边界

Abstract: Anomaly detection identifies rare, deviating samples in high-dimensional data and underpins many data-mining and intelligent-diagnosis systems. Existing evaluation practice, however, is fragmented across modalities and rarely models the label contamination that pervades real annotation. We present a unified, contamination-aware benchmark spanning tabular, time-series, graph, image and text modalities, evaluating 26 algorithms over 29 real-world datasets, together with a plug-and-play active denoising defense. Through four progressive experiments we characterize clean-data performance ceilings, degradation trajectories under 0%–20% symmetric label flips, cross-modal relative difficulty, and the rescue effect and failure boundary of the defense under heavy contamination. An IQR-based sample-trimming defense (IQR_Trim) restores up to 2.52 AUC-ROC points for an MLP under 20% noise and consistently beats label correction, while inducing mild negative transfer on logistic regression and TabPFN—an empirical instance of the No-Free-Lunch principle in robust denoising.

Keywords: Anomaly Detection; Cross-Modal Benchmark; Label Contamination; Robust Learning; Active Denoising Defense; Failure Boundary

1 引言

异常检测 (Anomaly Detection, AD) 旨在从高维数据中识别与正常分布存在显著偏离的少数样本,在金融欺诈识别、医疗辅助诊断、网络入侵检测与工业设备故障预警等场景中具有重要价值。经过数十年发展,针对不同数据形态已涌现出大量算法族群,但在面向真实部署的系统性评估上,该领域仍存在两个长期未被充分回应的问题:评测口径的跨模态割裂,以及对标签污染鲁棒性的刻画缺失。

首先,表格、时序、图、图像与文本五类模态在几何结构、样本依赖关系与特征表征上差异巨大,导致各模态的算法体系与评测基准长期相互独立地发展。这种割裂使得“哪一类方法在何种数据形态下更具优势”这一基本问题难以在统一标准下获得回答。其次,在真实标注流程中,由于人工核验成本高昂、传感器

漂移或多源标注冲突,训练集往往混入比例不一的标签噪声,其中最具代表性的建模为对称标签翻转 (Symmetric Label Flips)^[1]。高容量监督模型会过度拟合这些被错误标记的样本,造成决策边界畸变与泛化性能的显著下降。

针对上述问题,本文构建了一个统一的跨模态抗污染异常检测基准平台,覆盖表格 (Tabular)、时序 (TimeSeries)、图 (Graph)、图像 (CV) 与文本 (NLP) 五大模态,在 29 个真实数据集上系统评测了 26 种经典与前沿算法,并针对重度对称标签翻转设计了一种即插即用的主动去噪防御包装器 (Robust Defense Wrapper),系统考察了其有效区间与失效边界。

1.1 研究背景与动机

A 跨模态统一评测的价值

异常检测算法的优劣具有很强的数据驱动与模态依赖特性。在表格数据中，样本间缺乏显式的时空关联，基于树集成（如 LightGBM^[2]、XGBoost^[3]）与邻近度量（如 KNN^[4]）的方法通常能较好刻画局部分类边界；在时序数据中，异常往往隐含于时间依赖与局部突变之中，基于预测重构（如 LSTM 自编码器）与子序列距离（如 Matrix Profile）的无监督方法更为主流；而在图数据中，融合拓扑结构与节点属性的图神经网络（如 GCN^[5]）是捕获结构性异常的关键。

然而，现有评测基准大多局限于单一模态，缺乏在相同污染标准、相同数据接口下进行横向比较的能力。构建统一的跨模态评测底座，不仅能够客观比较不同算法族群的泛化能力，也为探索具有统一架构的异常检测基础模型（Foundation Models for Anomaly Detection）提供实证支撑。

B 标签污染下的鲁棒性挑战

在工程落地中，标签噪声几乎不可避免。对称标签翻转会从两个层面损害监督学习：其一，多层感知机等高容量判别器会强行拟合被翻转的样本，使高维决策面发生扭曲，在干净测试集上出现明显性能跌落；其二，部分线性或弱判别模型在混淆标签下梯度方向相互抵消，易退化为预测先验众数的平凡解。

因此，设计一种无需重训练底层分类器、具备即插即用特性的主动鲁棒防御机制^[6]，对维持异常检测系统的长期可靠运行具有现实意义。然而，去噪干预本身是否始终有益、对哪些模型可能产生反效果，这一“边界问题”在现有研究中尚缺乏系统的实证刻画。

1.2 研究内容与主要贡献

本文围绕“统一评测”与“主动防御”两条主线，组织了四组由浅入深、层层递进的实验：

1. **无噪基准评估 (Exp1)**：在 5 大模态、29 个数据集上建立统一的无噪性能基准，比较监督与无监督方法在理想标注下的性能上限，并以 Friedman 平均秩给出全局排名。
2. **噪声退化评估 (Exp2)**：在 0%–20% 的对称标签翻转梯度下，刻画各算法的渐进退化轨迹，量化其固有鲁棒性。

3. **模态难度分析 (Exp3)**：以归一化性能差距量化各模态寻找最优决策面的相对难度，并给出跨模态综合排名。

4. **主动防御消融 (Exp4)**：在表格模态上，针对 20% 重度污染，横向消融 9 种无监督清洁剂在样本剪裁 (Trim) 与标签纠正 (Flip) 两种策略下对 6 种下游分类器的去噪效果，并界定其失效边界。

A 主要贡献

本文的主要贡献可概括为以下三点：

1. **统一的跨模态抗污染评测平台**。我们设计并实现了一条可同时加载、对齐并以统一标准接口输出表格、时序、图、CV 与 NLP 数据的评测流水线，集成 26 种算法的自动化评估，显著降低了跨模态比较的适配成本。
2. **即插即用的主动去噪防御及其有效性验证**。我们证实基于样本剪裁的无监督去噪防御（尤以 IQR_Trim 为代表）在 20% 重度标签噪声下几乎不损害干净数据表现，并能使多层感知机的 AUC-ROC 绝对回升 **2.52** 个百分点；同时，剪裁策略在所有清洁剂上均稳定优于标签纠正策略。
3. **去噪防御失效边界的实证刻画**。我们从经验与机制两方面分析了样本剪裁防御在表格基础模型 TabPFN^[7] 与线性逻辑回归上的负迁移现象，将其归因于上下文密度破坏与边界支撑点流失，为“没有免费的午餐”原则在去噪鲁棒学习中的体现提供了具体证据，并据此给出模型相关的部署建议。

B 组织结构

本文后续章节安排如下：第 2 节综述异常检测算法体系、标签噪声学习与现有评测基准；第 3 节阐述统一数据管道、对称标签污染模型与主动去噪防御框架；第 4 节介绍数据集、对比算法、评测指标与实验环境；第 5 节报告 Exp1–Exp4 的实验结果；第 6 节针对噪声下的监督/无监督性能反转与防御失效边界展开深入讨论；第 7 节总结全文并展望未来工作。

2 相关工作

2.1 异常检测算法体系

异常检测方法可大致分为无监督与（半）监督两条技术路线。无监督方法不依赖标注，依据样本在特征空间中的统计规律识别离群

点,代表性方法包括基于密度的 LOF、基于近邻距离的 KNN、基于路径隔离的隔离森林 (IForest)、基于核边界的一类支持向量机 (OCSVM)^[8],以及近年来基于概率分布的 ECOD 与 COPOD 等高效估计器;这类方法被 PyOD^[4]等工具箱系统集成。深度方法则通过自编码器的重构误差^[9]或深度单类支持向量描述 (DeepSVDD) 刻画正常流形。当标注可得时,梯度提升树 (LightGBM^[2]、XGBoost^[3]) 与神经网络等监督判别器通常能取得更高的检测上限。在时序与图模态下,方法进一步专门化,分别发展出循环重构、子序列距离与图神经网络等代表性技术。

2.2 标签噪声学习与鲁棒训练

标签噪声是监督学习中的经典难题。Frénay 与 Verleysen^[1]系统综述了噪声的成因与建模方式,其中对称标签翻转因其简洁的转移矩阵形式而被广泛用作鲁棒性评测的标准设定。应对标签噪声的策略大致可分为三类:损失函数修正(如鲁棒损失与重加权)、噪声转移矩阵估计,以及样本选择与净化。本文采用的样本剪裁与标签纠正属于第三类——通过识别并处理可疑样本来净化训练集^[6]。与多数需要修改训练目标或重训练模型的方法不同,本文将去噪过程封装为与下游分类器解耦的、即插即用的前置包装器,从而可在不改动既有检测模型的前提下提升其抗噪能力。

2.3 异常检测评测基准

近年来,社区陆续发布了若干高质量评测框架,但其覆盖范围均受限于单一模态:

- **ADBench**^[10] 是表格异常检测的里程碑式基准,系统比较了大量算法在有噪/无噪等多种设定下的表现,并提供了由 ResNet 与 BERT 提取的 CV/NLP 嵌入数据;但其不涵盖时序与图模态,难以评估时间依赖与结构相关性。
- **TSB-AD**^[11] 是时序异常检测领域的权威端到端评测底座,涵盖多种异常类型与预测/重构模型,但不具备对表格、图等模态的横向评测能力。
- **GADBench**^[5] 面向图异常检测,系统比较了传统图算法与图神经网络,但评估面局限于结构化网络数据。

如 1 所示,上述基准在模态覆盖与污染评测两个维度上均存在空白。本文的工作旨在弥合这一空白:在统一的数据接口与一致的对称

标签污染标准下,实现五大模态的横向可比评测,并在此之上引入主动去噪防御这一新的评估维度。

3 方法与系统架构

本节阐述本文设计的统一抗污染评测基准与主动去噪防御体系。整个系统由五个阶段串联而成:多模态输入与特征对齐、对称标签污染注入、主动去噪防御(样本剪裁与标签纠正双路径)、下游检测算法评估,以及多指标度量与失效边界界定。端到端数据流与评测闭环如 1 所示。

3.1 统一跨模态数据管道

与仅聚焦单一模态的既有框架 (ADBench^[10]、TSB-AD^[11]、GADBench^[5]) 不同,本文设计了一条覆盖五大模态的统一数据管道。其核心挑战在于:异构模态在特征维度、样本依赖性与输入表征上差异显著。为此,我们对各模态执行差异化的标准化与嵌入对齐,最终统一封装为元组 $(X, Y) \in \mathbb{R}^{N \times D} \times \{0, 1\}^N$, 其中 $y_i = 1$ 表示异常、 $y_i = 0$ 表示正常:

1. **表格 (Tabular)**: 直接规整为实数矩阵 $X_{\text{tab}} \in \mathbb{R}^{N \times d}$, 按训练集统计量做 z-score 标准化。
2. **时序 (TimeSeries)**: 以滑动窗口构造 $X_{\text{ts}} \in \mathbb{R}^{N \times L \times d}$ (L 为窗口长度), 保留局部与长程时间依赖, 供循环重构与子序列距离方法使用。
3. **图 (Graph)**: 表示为 $\mathcal{G} = (V, E)$, 构建节点特征矩阵 $X_{\text{node}} \in \mathbb{R}^{|V| \times d}$ 与邻接矩阵 A , 供图神经网络 (GCN^[5]) 联合聚合拓扑与属性。
4. **图像与文本 (CV & NLP)**: 原始图像与文本分别经预训练 ResNet^[12] 与 BERT 骨干网络投影为稠密语义向量 $X_{\text{embed}} \in \mathbb{R}^{N \times D_e}$ (CV 为 512 维, NLP 为 768 维), 从而与表格接口兼容。

经统一封装,所有上层算法均可通过一致的 `.fit(X, Y)` 与 `.predict_proba(X)` 接口调用,消除了跨模态评测的适配壁垒。

3.2 对称标签污染模型

为刻画真实标注中的标签噪声,本文采用对称标签翻转模型^[1]。设干净训练集为 $\mathcal{D}_{\text{clean}} = \{(x_i, y_i)\}_{i=1}^N$, 观测到的含噪集为 $\mathcal{D}_{\text{dirty}} = \{(x_i, \tilde{y}_i)\}_{i=1}^N$ 。标签转移由矩阵 $T \in [0, 1]^{2 \times 2}$ 控制,其元素

表 1 代表性异常检测评测基准的覆盖范围对比 (✓表示支持, —表示不支持)

基准	表格	时序	图	图像	文本	标签污染评测	主动去噪防御
ADBench ^[10]	✓	—	—	✓	✓	部分	—
TSB-AD ^[11]	—	✓	—	—	—	—	—
GADBench ^[5]	—	—	✓	—	—	—	—
本文	✓	✓	✓	✓	✓	✓	✓




图 1 统一跨模态抗污染异常检测基准的数据流与评测闭环

$T_{jk} = P(\tilde{y} = k \mid y = j)$ 。在对称设定下, 正负两类被误标的概率相等, 均为污染率 η :

$$T = \begin{pmatrix} 1-\eta & \eta \\ \eta & 1-\eta \end{pmatrix}, \quad \eta \in [0, 0.2]. \quad (1)$$

我们以伯努利试验对训练标签注入噪声, 并**仅污染训练集、完整保留干净测试集**, 以保证 AUC-ROC、AUC-PR 等评测指标的无偏性。

3.3 主动去噪防御框架

监督分类器易过拟合 $\mathcal{D}_{\text{dirty}}$ 中的噪声样本, 导致决策边界畸变。为此, 本文提出即插即用的主动去噪防御包装器, 其基本思想是: 利用无监督异常检测器在特征空间中的几何规律, 识别那些与其局部特征显著相悖的标签噪声样本, 并加以剔除或纠正。设 f_{unsup} 为无监督清洁剂, 对每个样本输出异常得分

$$s_i = f_{\text{unsup}}(x_i), \quad i = 1, \dots, N. \quad (2)$$

据此, 包装器提供两条可消融的技术路径:

- **样本剪裁 (Trim)**^[6]: 标注为“正常” ($\tilde{y}_i = 0$) 但得分极高的样本极可能是漏标异常; 标注为“异常” ($\tilde{y}_i = 1$) 但得分极低的样本极可能是误标正常。Trim 按污染率比例剔除这部分最可疑样本, 仅在保留子集上训练

下游模型:

$$\mathcal{D}_{\text{trim}} = \{(x_i, \tilde{y}_i) \mid i \in \mathcal{I}_{\text{retained}}\}. \quad (3)$$

剔除可疑样本可直接消除其在损失反向传播中引入的梯度扰动。

- **标签纠正 (Flip)**: 保留全部样本, 但将识别出的高风险样本标签翻转为 $1 - \tilde{y}_i$ 。该路径不损失样本量, 但高度依赖无监督检测器在决策边界附近的判别精度。

完整的去噪防御流程如 0.1 所示。其关键在于: 清洁剂仅在特征 X 上拟合 (不接触标签), 随后将无监督判定与给定标签相悖的样本视为可疑, 再按所选策略剔除或纠正。整个包装器与下游分类器解耦, 无需修改其训练目标。

[!t] 算法 0.1 主动去噪防御包装器

输入: 含噪训练集 $\mathcal{D}_{\text{dirty}} = \{(x_i, \tilde{y}_i)\}_{i=1}^N$; 无监督清洁剂 f_{unsup} ; 去噪比例 ρ ; 策略 STRAT $\in \{\text{TRIM}, \text{FLIP}\}$; 下游分类器 C

输出: 鲁棒分类器 C^*

- 1: 在特征 $\{x_i\}_{i=1}^N$ 上拟合 f_{unsup} ▶ 不使用标签
- 2: $s_i \leftarrow f_{\text{unsup}}(x_i), i = 1, \dots, N$ ▶ 无监督异常得分
- 3: $\hat{y}_i \leftarrow \mathbb{1}[s_i \geq \tau_\rho]$ ▶ 以 ρ 分位阈值 τ_ρ 判定

```

4:  $S \leftarrow \{i : \hat{y}_i \neq \tilde{y}_i\}$  ▶ 标签与判定相悖的可疑样本
5: if STRAT = TRIM then
6:    $\mathcal{D}_{\text{clean}} \leftarrow \{(x_i, \tilde{y}_i) : i \notin S\}$  ▶ 剔除
7: else
8:    $\mathcal{D}_{\text{clean}} \leftarrow \{(x_i, \tilde{y}_i \oplus \mathbb{K}[i \in S])\}_{i=1}^N$  ▶ 纠正
9: end if
10:  $C^* \leftarrow \text{TRAIN}(C, \mathcal{D}_{\text{clean}})$ 
11: return  $C^*$ 

```

图 2 以二维特征空间并列示意了两种策略的差异：二者都从同一含噪训练集出发，剪裁直接剔除标签与特征相悖的可疑样本，使决策边界恢复洁净；而纠正在翻转标签时，一旦无监督检测器在边界附近误判，便会引入二次噪声并使边界偏斜。这从几何上解释了 Exp4 中 Trim 全面优于 Flip 的现象。

A 典型无监督清洁器

本文在 Exp4 中消融了 9 种无监督清洁器^[4]。下面给出表现最具代表性的三种的数学机制。

a. IQR 统计清洁器

对第 j 维特征，计算上、下四分位数 $Q_3^{(j)}, Q_1^{(j)}$ ，四分位距为 $\text{IQR}^{(j)} = Q_3^{(j)} - Q_1^{(j)}$ ，合理区间为

$$[Q_1^{(j)} - 1.5 \text{IQR}^{(j)}, Q_3^{(j)} + 1.5 \text{IQR}^{(j)}]. \quad (4)$$

在任一维超出该区间的样本被标记为候选离群点。该方法为非参数统计，不依赖分布假设。

b. 隔离森林清洁器

通过随机特征与随机分裂构建 M 棵孤立树，异常样本因更易被孤立而具有更短的平均路径长度 $\mathbb{E}(h(x))$ ，其异常得分为

$$s(x, n) = 2^{-\mathbb{E}(h(x))/c(n)}, \quad (5)$$

其中 $c(n) = 2 \ln(n-1) + 0.5772 - 2(n-1)/n$ 为归一化常数。当 $s \rightarrow 1$ 时，样本被判定为高置信度异常点。

c. 自编码器清洁器

编码器 f_{enc} 将输入压缩至低维瓶颈，解码器 f_{dec} 重构输入^[9]，训练目标为重构均方误差

$$\mathcal{L}_{\text{MSE}} = \frac{1}{N} \sum_{i=1}^N \|x_i - \hat{x}_i\|_2^2, \quad \hat{x} = f_{\text{dec}}(f_{\text{enc}}(x)). \quad (6)$$

由于模型倾向拟合占多数的正常样本，噪声与异常样本的重构误差显著偏高，据此即可定位并实施剪裁。

B 下游分类器与评估

净化后的训练集被注入 6 种下游分类器进行评估：多层感知机 (MLP)、梯度提升树 (LightGBM、XGBoost)、随机森林 (RF)、表格基础模型 TabPFN^[7] 与逻辑回归 (LR)。系统以 AUC-ROC、AUC-PR 及训练/推理耗时为指标，在干净测试集上输出最终评测，并据此界定主动防御的有效区间与失效边界。

3.4 交互式诊断原型系统

为缩短研究与部署之间的距离，本文在算法底座之上实现了一个基于 Streamlit 的交互式诊断与可视化原型 (app/streamlit_app.py)，包含四个核心模块：(1) **多模态数据浏览**，检索 29 个数据集的元特征并支持 PCA/t-SNE 降维可视化；(2) **污染退化模拟**，交互式调节污染率 $\eta \in [0\%, 20\%]$ 并实时渲染各分类器的退化曲线；(3) **精度-效率权衡面板**，以散点图呈现检测指标与耗时的帕累托前沿，辅助部署选型；(4) **主动防御消融面板**，自由组合清洁器与策略，展示防御对下游性能的影响，并根据下游模型类型给出基于失效边界的部署提示。该原型将“数据管道—污染注入—去噪防御—下游训练—部署诊断”的完整闭环进行了工程化呈现。

4 实验设计

本节介绍数据集、对比算法、评测指标与实验环境。除特别说明外，表格、CV、NLP 数据均按 7:3 做分层划分，仅以训练集统计量对特征做 z-score 标准化，以避免测试信息泄露。为降低随机性影响，Exp1-Exp3 在随机种子 {41, 42, 43} 下重复并取平均，Exp4 使用固定种子 42。所有评测指标均在完整保留的干净测试集上计算。




图 2 样本剪裁 (Trim) 与标签纠正 (Flip) 两种去噪策略的特征空间示意

4.1 数据集

评测数据池涵盖 5 大模态、共 29 个真实数据集实例，具体统计见 2：

- 表格 (9 个)：**取自 ADBench^[10]，覆盖医学诊断 (cardio、thyroid、annthyroid、mam-mography)、遥感 (satellite)、航天测控 (shuttle)、金融反欺诈 (credit_card)、糖尿病筛查 (pima) 与手写体识别 (pendigits)，异常率从 0.17% 到 34.9% 不等，包含高维与极不平衡等典型挑战。
- 图像 (4 个)：**取自 ADBench 的 CV 子集 (CIFAR-10、Fashion-MNIST)，原始像素经预训练 ResNet-18 提取为 512 维语义嵌入^[12]。
- 文本 (4 个)：**取自 20 Newsgroups、AG-News 与 Amazon Review，经 BERT 映射为 768 维稠密向量。
- 时序 (8 个)：**取自 TSB-AD^[11] 的单变量子集，覆盖网络流量 (NAB)、心电诊断 (MITDB)、航天器传感器 (MSL/SWaT)、Web 服务 (IOPS) 及合成序列 (MGAB) 等领域，保留复杂的时间依赖特征。
- 图 (4 个)：**取自 GADBench^[5]，包括金融交易网络 (tfinance，节点数达 39,357)、社交网络 (reddit)、电商共购网络 (amazon) 与微博欺诈网络 (weibo)，兼具高维节点特征与拓扑结构。

4.2 对比算法

我们共评测 26 种算法。其中 14 种为**跨模态通用算法**（在表格、CV、NLP 上统一评测），其余为**模态专用算法**。

A 跨模态通用算法 (14 种)

监督/半监督 (5 种)：LightGBM^[2] ($n_estimators=100$, $learning_rate=0.05$, 叶子数 31)、XGBoost^[3] ($n_estimators=100$, $max_depth=6$)、多层感知机 MLP (隐藏层 128-64, ReLU+Dropout, Adam, 学习率 0.001, 20 轮)、随机森林 RF，以及逻辑回归 LR (L2 正则, $max_iter=1000$) 作为线性基线。**无监督 (9 种)**，均基于 PyOD^[4] 实现：隔离森林 IForest (100 棵孤立树)、自编码器 AE (瓶颈结构 $d-d/2-d/4$)、局部异常因子 LOF ($k=20$)、一类支持向量机 OCSVM (RBF 核)^[8]、 k -近邻 KNN、COPOD、ECOD、DeepSVDD 与 IQR 统计检测器。

B 模态专用算法 (12 种)

表格基础模型：TabPFN^[7]，基于在大量合成先验上元学习的 Transformer，对中小规模表格无需迭代训练即可给出贝叶斯后验预测，采用官方默认推理设置。**时序 (5 种)：**有监督循环神经网络 LSTM-Sup、循环自编码器 LSTM-AE (隐藏维 64)、子序列距离 Matrix Profile、卷积特征分类器 MiniRocket，以及 DADA。**图 (6 种)：**图卷积网络 GCN^[5]、BWGNN、DOMINANT、对比学习 CoLA、提示学习 UNPrompt，以及树模型基线 XGBGraph。

需要说明的是，Exp1 在各模态上评测全部相应算法（含模态专用模型）；Exp2-Exp4 涉及标签翻转与监督训练，统一在 14 种通用算法（表格上额外含 TabPFN）上进行。

表 2 跨模态抗污染评测基准的数据集统计（图模态规模以节点数计；时序异常率为逐点比例）

模态	数据集	样本/节点数	特征维度	异常率 (%)
表格 (Tabular)	cardio	1,831	21	9.61
	thyroid	3,772	6	2.47
	satellite	6,435	36	31.64
	shuttle	49,097	9	7.15
	credit_card	284,807	29	0.17
	pima	768	8	34.90
	annthyroid	7,200	6	7.42
	mammography	11,183	6	2.32
	pendigits	6,870	16	2.27
图像 (CV)	cifar10_0	5,263	512	5.00
	cifar10_1	5,263	512	5.00
	fashionmnist_0	6,315	512	4.99
	fashionmnist_1	6,315	512	4.99
文本 (NLP)	20news_0	3,090	768	4.98
	20news_1	2,514	768	4.97
	agnews_0	10,000	768	5.00
	amazon	10,000	768	5.00
时序 (TimeSeries)	NAB_Traffic	3,344	1	19.53
	Stock_Finance	2,441	1	99.74
	MITDB_Medical	109,991	1	3.97
	MGAB_Synthetic	32,491	1	1.56
	IOPS_WebService	26,405	1	6.12
	UCR_Facility	134,991	1	0.21
	UCR_HumanActivity	64,991	1	0.15
	SWaT_Sensor	81,312	1	14.15
图 (Graph)	tfinance	39,357	10	4.58
	reddit	10,984	64	3.33
	amazon	11,944	25	6.87
	weibo	8,405	400	10.33

4.3 评测指标

为避免准确率在极度不平衡场景下的误导,我们采用两类曲线下面积指标。**AUC-ROC** 刻画真阳率 $\text{TPR} = \frac{\text{TP}}{\text{TP}+\text{FN}}$ 与假阳率 $\text{FPR} = \frac{\text{FP}}{\text{FP}+\text{TN}}$ 的权衡,反映模型整体排序能力;**AUC-PR** 由精确率 $\frac{\text{TP}}{\text{TP}+\text{FP}}$ 与召回率 $\frac{\text{TP}}{\text{TP}+\text{FN}}$ 构成,更敏感于少数类,在极低异常率(如 credit_card 的

0.17%)下更能反映假阳性的影响。此外,我们记录训练与推理耗时以评估效率。

4.4 实验环境

所有实验均在同一服务器上完成,软硬件配置见 3。

表 3 实验软硬件环境

类别	配置
CPU	Intel Xeon Platinum 8352B @ 2.70GHz (32 核 / 64 线程)
GPU	NVIDIA GeForce RTX 4090 (24 GB 显存)
内存	128 GB DDR4 ECC
存储	2 TB NVMe SSD
操作系统	Ubuntu 22.04 LTS (Linux 5.15)
运行环境	Python 3.10 (Miniconda)
深度学习	PyTorch 2.1.2 + CUDA 12.1
机器学习	Scikit-Learn 1.3.2 / NumPy 1.24
异常检测	PyOD 1.1.2 ^[4]
树模型	LightGBM 4.1.0 / XGBoost 2.0.0




图 3 Exp1 无噪状态下 14 种通用算法的 Friedman 平均秩 (值越小越优)

5 实验结果与分析

本节依次报告四组实验的结果：无噪基准 (Exp1)、噪声退化 (Exp2)、模态难度 (Exp3) 与主动防御消融 (Exp4)。

5.1 无噪基准评估 (Exp1)

Exp1 评估各算法在干净标注下的性能上限。我们汇总了各算法在所属模态数据集上的测试集 AUC-ROC，并对 14 种跨模态通用算法计算全局 Friedman 平均秩，结果见 3。各模态的领先算法与最优 AUC-ROC 汇总于 4。

由此可得三点观察：

1. **监督模型在干净标注下占据主导。** Friedman 前五名均为监督算法：LightGBM (2.26)、XGBoost (2.82)、MLP (3.12)、RF (3.50)、LR (3.94)。在标注完全纯净时，高容量判别模型能够充分拟合特征空间中的非线性边界。
2. **无监督模型存在天然上限。** 无监督方法中自编码器与 KNN 表现最佳 (平均秩并列

表 4 Exp1 各模态领先算法与最优/平均 AUC-ROC

模态	最优算法	最优 AUC	模态均值
	TabPFN	0.966	0.861
图像	LightGBM	0.940	0.815
文本	MLP	0.926	0.683
图	XGBGraph	0.902	0.714
时序	MiniRocket	0.809	0.668

8.41)，IForest (9.12) 次之，LOF (10.94) 靠后。由于其仅依赖特征分布而不使用标签，决策能力天然弱于监督模型。

3. **模态专用模型在结构化数据上不可或缺。** 在图与时序模态，通用算法让位于专用模型——图模态由 XGBGraph (0.902)、BWGNN (0.892)、GCN (0.884) 领先，时序模态由 MiniRocket (0.809) 领先。值得注意的是，时序最优 AUC 仅约 0.81，远低于表格的 0.97，预示该模态的高难度 (详见 Exp3)。

各算法的平均秩、平均 AUC-ROC 与平均 AUC-PR 汇总于 5。值得注意的是，AUC-PR 维度上监督与无监督的差距 (监督 0.69–0.77，无监督 0.16–0.32) 远大于 AUC-ROC 上的差距：无监督方法虽能给出合理的整体排序，却在少数类的精确召回上明显不足。此外，AUC-ROC 在极端不平衡数据上存在乐观偏置——例如在 credit_card (异常率 0.17%) 上监督模型平均 AUC-ROC 达 0.962，而 AUC-PR 仅 0.810，这说明在不平衡场景下需并用两类指标方能客观评估。

Nemenyi 检验的关键差值图 (图 4) 进一步表明，监督算法与无监督算法之间的平均秩差超过临界差值 (CD)，差异具有统计显著性；而监督算法内部、以及多数无监督算法之间的秩差则落在 CD 之内，难以显著区分。图 6 的逐数据集 AUC-ROC 热力图直观印证了这一格局：监督算法 (上部) 在表格、CV、NLP 上整体呈现高值，而无监督算法的表现更依赖具体数据集。

效率方面 (图 5)，树模型与线性模型的训练耗时较深度模型低 2–3 个数量级，在精度–效率权衡上更贴近帕累托前沿。

5.2 噪声退化评估 (Exp2)

Exp2 在训练集上注入 0%–20% 的对称标签翻转，刻画各算法的退化轨迹。各模态退化

表 5 Exp1 通用算法的 Friedman 平均秩与平均 AUC-ROC / AUC-PR（秩越小越优）

算法	平均秩	AUC-ROC	AUC-PR
LightGBM	2.26	0.940	0.742
XGBoost	2.82	0.940	0.737
MLP	3.12	0.944	0.770
RF	3.50	0.927	0.693
LR	3.94	0.932	0.730
AutoEncoder	8.41	0.764	0.258
KNN	8.41	0.744	0.230
IForest	9.12	0.767	0.315
ECOD	10.06	0.747	0.308
COPOD	10.53	0.747	0.288
DeepSVDD	10.53	0.729	0.261
IQR	10.53	0.731	0.262
OCSVM	10.82	0.726	0.232
LOF	10.94	0.636	0.164

Nemenyi Critical Difference diagram (auc_roc)




图 4 Exp1 Nemenyi 关键差值 (CD) 图：横轴为 Friedman 平均秩，横线相连者差异不显著




图 5 Exp1 精度-效率权衡：纵轴为 AUC-ROC，横轴为训练耗时（对数刻度）

表 6 Exp2 在 20% 污染下监督/无监督两组的平均 AUC-ROC 跌幅（百分点；负值表示性能不降反升）

模态	监督组	无监督组
表格	3.34	6.98
图像	14.10	2.31
文本	16.34	0.67
图	5.89	6.00
时序	19.67	-1.16

曲线见 7，监督与无监督两组在 20% 污染下的平均 AUC-ROC 跌幅见 6。

退化曲线揭示出以下规律：

- 监督模型随噪声单调退化，且模态间差异显著。** 监督组在所有模态均随 η 增大而下降，但跌幅高度依赖模态：表格最轻（约 3.3 个百分点），图像、文本、时序最重（14–20 个百分点）。其中 MLP 在文本上的跌幅最大（约 22.8 个百分点），因其在预训练嵌入上的非线性边界对翻转标签极为敏感；而表格中存在大量冗余、规模庞大的数据集，对固定比例的标签噪声具有更强的稀释效应。
- 无监督模型对标签噪声具有结构性免疫。** 由于训练时不读取标签，多数无监督方法的跌幅极小（文本仅 0.67、图像 2.31 个百分点）。例外出现在表格模态：基于距离/密度的 LOF、KNN 在该设定下退化明显（无监督组均值被抬高至 6.98），表明这类方法对训练分布的扰动较为敏感。
- 时序模态出现性能反转。** 时序无监督组的平均跌幅为 -1.16 个百分点，即整体不降反升，而监督组骤降约 19.7 个百分点。这一交叉现象意味着在重度污染下，无监督方法将反超监督方法，详见第 6 节的专题讨论。

图 8 以热力图汇总了各算法在各模态下从 0% 到 20% 的 AUC-ROC 跌幅，可清晰看出监督算法（暖色块集中）与无监督算法（普遍偏冷）在抗噪性上的系统性差异。

5.3 模态难度与跨模态排名 (Exp3)

Exp3 以各模态的平均与最优 AUC-ROC 量化“寻找最优决策面”的相对难度（参见 4）。难度由低到高（均值由高到低）依次为：表格 (0.861)、图像 (0.815)、图 (0.714)、文本 (0.683)、时序 (0.668)；即便取各模态最优算




图 6 Exp1 全部通用算法在各数据集上的无噪 AUC-ROC 热力图（颜色越暖表示性能越高）




图 7 Exp2 不同模态下监督与无监督模型的渐进退化轨迹

法，时序仍仅达 0.793，显著低于其余模态。
进一步分析可得：

1. 时序与图模态难度最高。时序数据蕴含相位偏移与长程依赖，图数据具有非欧拓扑

关系，二者均使依赖独立同分布假设的通用算法搜索受阻，必须借助专用模型。

2. 监督树模型与 MLP 跨模态泛化最稳健。按跨模态平均 AUC-ROC 排名，RF (0.859)、TabPFN (0.856)、LightGBM (0.848)、XGBoost (0.847)、MLP (0.846) 位居前列，显示出在异构模态上的一致表达能力（图 9b）。

算法-模态交叉热力图（图 10）进一步刻画了“算法 × 模态”的适配格局：监督模型在表格与图像上普遍取得高分，而文本与时序则对算法选择更为敏感，仅少数方法能维持较高性能。

5.4 主动防御消融（Exp4）

Exp4 在表格模态、20% 重度污染下，消融 9 种无监督清洁器在 Trim 与 Flip 两种策略下对 6 种下游分类器的去噪效果。最优组合 IQR_Trim 相对无防御基线的挽救幅度见 7，整体消融见 11，最优防御者的跨数据集包络




图 8 Exp2 各算法在五大模态下由 0% 至 20% 污染的 AUC-ROC 跌幅热力图（颜色越暖跌幅越大）




图 9 Exp3 跨模态难度与顶尖算法的多模态性能足迹见 12。

由消融结果可得三点结论：

1. **剪裁策略全面优于纠正策略。**在所有清洁器上，_Trim 的最终 AUC-ROC 均高于对应的 _Flip：跨清洁器平均看，Trim 相对基线的损失约为 -0.9 至 -2.3 个百分点，而 Flip 高达 -4.5 至 -7.0 个百分点。Flip 依赖无监督检测器在决策边界附近的判别，一

表 7 Exp4 在 20% 污染下 IQR_Trim 防御对各下游分类器的 AUC-ROC 影响

下游分类器	无防御	IQR_Trim	Δ (pp)
MLP	0.938	0.963	+2.52
XGBoost	0.954	0.967	+1.26
LightGBM	0.960	0.970	+0.95
RF	0.962	0.969	+0.61
LR	0.960	0.948	-1.21
TabPFN	0.982	0.974	-0.75

旦误判便会引入“二次标签噪声”；而 Trim 直接剔除可疑样本，为下游模型保留了高纯度的训练子集。

2. **IQR_Trim 与高容量监督模型构成最佳组合。**在 20% 污染下，IQR_Trim 使 MLP 的




图 10 Exp3 算法-模态 AUC-ROC 交叉热力图




图 11 Exp4 不同清洁剂与策略 (Trim/Flip) 的去噪性能提升消融

AUC-ROC 绝对回升 **2.52** 个百分点，几乎抹平噪声带来的损失；对 XGBoost、LightGBM、RF 亦分别带来 +1.26、+0.95、+0.61 个百分点的提升。IQR 作为非参数统计方法，在剔除单维极端离群点时具有很高的




图 12 Exp4 在 20% 污染下 IQR_Trim 防御与无防御基线的跨数据集性能包络

置信度。

3. 防御存在明确的失效边界。如 7 下半部分所示，同一 IQR_Trim 防御对逻辑回归 (-1.21) 与 TabPFN (-0.75) 产生负迁移。这一“有得有失”的分化印证了去噪鲁棒学习中的“没有免费的午餐”原则，其机制将在第 6 节展开。

6 深入讨论

本节针对两个最具启发性的现象展开讨论：时序模态下监督与无监督方法的性能反转，以及主动防御的失效边界，并在此基础上给出部署建议。

6.1 时序模态下的性能反转

Exp2 显示，时序模态在重度污染下出现了显著的性能反转：监督组的平均 AUC-ROC 跌幅高达约 19.7 个百分点，而无监督组整体不降反升（约 +1.16 个百分点，见 6）。这意味着随着噪声加剧，原本在干净标注下落后的无监督方法将反超监督方法。该现象可从以下三方面理解：

1. **无监督方法对标签噪声的结构性免疫。**重构造型与距离型无监督方法（如自编码器、KNN、Matrix Profile）在训练时完全不读取标签，其优化目标仅为最小化重构误差或刻画子序列距离：

$$\mathcal{L}_{\text{Recon}} = \|X_{\text{ts}} - \hat{X}_{\text{ts}}\|_F^2. \quad (7)$$

因此，无论标签如何翻转，其学到的表征不受影响——这正是其高污染下保持稳定的根本原因。

2. **监督循环模型对翻转标签的过拟合。**时序异常通常为稀有事件（异常占比常低于 5%）。在 20% 对称污染下，翻转产生的伪异常数量甚至可能超过真实异常，使交叉熵损失的梯度方向被伪正/伪负样本主导，模型易退化为平凡解，时间上下文表征随之崩坏。
3. **监督方法在时序上的优势本就脆弱。**即便在干净标注下（Exp1），循环自编码器 LSTM-AE (0.738) 已优于有监督的 LSTM-Sup (0.687)，而表现最佳的是无需标签训练的卷积特征方法 MiniRocket (0.809)。这表明在时序模态，监督信号带来的增益有限，一旦标签受污染便迅速被噪声抵消。

6.2 主动防御的失效边界

Exp4 表明，IQR_Trim 对 MLP 与树集成模型带来正向挽救，却对逻辑回归（-1.21 个百分点）与 TabPFN（-0.75 个百分点）产生负迁移；若进一步在所有清洁器上平均，二者的损失更为明显。这一分化恰是“没有免费的午餐”原则的具体体现（图 13）：高容量监督模型位于受益区，而线性 LR 与上下文学习的 TabPFN




图 13 主动剪裁防御对六种下游模型的净收益与失效边界

落入失效区。其机制如下：

1. **TabPFN：上下文密度被破坏。**TabPFN 是参数固定的预训练 Transformer，推理时将整个训练集作为上下文，通过注意力执行近似的贝叶斯后验推断：

$$P(y_* | x_{\text{test}}, \mathcal{D}) \approx \text{Softmax}(\text{Attn}(Q, K, V)). \quad (8)$$

其预测质量依赖训练集的局部密度结构。样本剪裁人为抹除了部分样本，破坏了上下文的密度分布，干扰了注意力的后验积分，反而削弱了其本就较强的抗噪能力。

2. **逻辑回归：边界支撑点流失。**LR 的分离超平面高度依赖紧贴决策边界的关键样本。IQR_Trim 基于单维分位数边界（式 4）剔除离群点，容易误删那些处于两类交界、对边界定位至关重要的“少数派”样本，导致线性决策面发生漂移与旋转，从而产生负迁移。

由此可见，主动剪裁防御的收益取决于下游模型的归纳偏置：对易过拟合噪声的高容量非线性模型有益，而对依赖完整样本密度或边界支撑点的模型则可能有害。

6.3 工业部署建议

基于上述分析，我们对高噪声、多模态场景下的异常检测部署给出以下建议：

1. **按模型容量匹配去噪策略。**对 MLP、GBDT 等高容量、易过拟合的下游模型，建议启用 IQR_Trim 或 IForest_Trim 前置防御，剪裁比例可参照估计的污染率。
2. **对线性与上下文学习模型谨慎去噪。**若下游为逻辑回归、线性 SVM 或 TabPFN，应避免激进剪裁，转而采用 L2 正则、鲁棒损失或扩大上下文宽度等被动抗噪手段。
3. **在时序等高难度模态优先考虑无监督方**

法。当标注质量难以保证时, 标签免疫的无监督/重构方法在鲁棒性上更具优势。

4. **保留小规模“黄金验证集”**。建议人工核验保留占比 1%–5% 的纯净验证集, 用于动态标定剪裁比例与判定阈值, 避免在含噪验证集上调参导致的过拟合。

6.4 有效性威胁与局限

为客观界定结论的适用范围, 本文指出以下局限:

1. **噪声模型**。本文仅考察对称标签翻转, 未涵盖更贴近真实标注的非对称与特征依赖噪声, 二者下的退化与防御行为可能不同。
2. **防御实验范围**。Exp4 的主动防御消融在表格模态、单一随机种子下完成; 其在时序、图等模态上的有效性, 以及结论的方差, 仍有待在多种子、多模态设定下进一步验证。
3. **清洁剂与去噪比例**。去噪比例 ρ 设为接近已知污染率 η , 而真实场景中 η 往往未知; ρ 的误设可能削弱甚至逆转防御收益。
4. **表征依赖**。CV/NLP 模态使用了预训练 ResNet/BERT 嵌入, 结论部分依赖于骨干网络的表征质量, 未必可直接迁移至端到端训练设定。

7 结论与展望

7.1 结论

针对异常检测评测中的跨模态割裂与标签污染鲁棒性缺失两大问题, 本文构建了一个覆盖表格、时序、图、图像与文本五大模态的统一抗污染评测基准, 在 29 个真实数据集上系统评测了 26 种算法, 并设计了一套即插即用的主动去噪防御。主要结论如下:

1. **统一评测底座**。我们实现了可对齐五大模态、以一致接口驱动 26 种算法的自动化评测流水线, 使不同算法族群得以在相同的污染标准下横向比较。
2. **噪声退化规律**。在干净标注下监督模型占优 (Exp1); 随污染加剧, 其退化幅度高度依赖模态, 在文本、时序上跌幅可达 16–20 个百分点, 而无监督方法因标签免疫而保持稳定, 并在时序模态出现监督/无监督性能反转 (Exp2、Exp3)。
3. **主动防御的有效性与边界**。基于样本剪裁的 IQR_Trim 在 20% 污染下使 MLP 的 AUC-ROC 回升 2.52 个百分点, 且剪裁策略稳定优于标签纠正; 但其对逻辑回归与

TabPFN 产生负迁移, 揭示了去噪防御的失效边界与“没有免费的午餐”原则 (Exp4)。

7.2 展望

本文仍有若干可拓展的方向:

1. **更真实的噪声模型**。本文聚焦对称标签翻转, 未来可研究非对称与特征依赖的标签噪声 (即靠近边界的模糊样本更易被误标), 并结合置信学习设计自适应去噪。
2. **大模型辅助的可解释异常检测**。可探索以推理大模型^[13]对时序、文本日志与图属性异常进行零样本判定与自然语言解释。
3. **联邦式主动防御**。在隐私保护的多端场景下, 研究不汇聚原始数据的分布式去噪与协同净化机制。

参考文献

- [1] FRÉDAY B, VERLEYSEN M. Classification in the Presence of Label Noise: A Survey[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence (T-PAMI), 2013, 36(5): 845-866.
- [2] KE G, MENG Q, FINLEY T, et al. LightGBM: A Highly Efficient Gradient Boosting Decision Tree[C]//Advances in Neural Information Processing Systems (NeurIPS): vol. 30. 2017: 3146-3154.
- [3] CHEN T, GUESTRIN C. XGBoost: A Scalable Tree Boosting System[C]//Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. 2016: 785-794.
- [4] ZHAO Y, NASRULLAH Z, LI Z. PyOD: A Python Toolbox for Scalable Outlier Detection[J]. Journal of Machine Learning Research (JMLR), 2019, 20(96): 1-7.
- [5] ANONYMOUS A. GADBench: A Graph Anomaly Detection Benchmark[C]//Advances in Neural Information Processing Systems (NeurIPS) Datasets and Benchmarks Track. 2024.
- [6] JIANG C, SHI J, OUTLIERS R. Robust learning with sample trimming and iterative label purification[C]//International Conference on Machine Learning (ICML). 2020: 4210-3220.
- [7] HOLLMANN N, MÜLLER S, EGGENSPERGER K, et al. TabPFN: A

Transformer That Solves Tabular Classification in a Second[C]//Advances in Neural Information Processing Systems (NeurIPS): vol. 35. 2022: 24151-24168.

- [8] SCHÖLKOPF B, WILLIAMSON R C, SMOLA A, et al. Support Vector Method for Novelty Detection[J]. Advances in Neural Information Processing Systems (NeurIPS), 1999, 12: 582-588.
- [9] AN J, CHO S. Variational Autoencoder based Anomaly Detection using Reconstruction Probability: Special Report[R]. Seoul National University, 2015.
- [10] HAN S, ZHAO O, JIANG J, et al. AD-Bench: Anomaly Detection Benchmark[C]//Advances in Neural Information Processing Systems (NeurIPS): vol. 35. 2022: 3214-3227.
- [11] PAPARRIZOS J, KANG Y, BROUSSO P, et al. TSB-AD: An Evaluation Pipeline for Time Series Anomaly Detection[J]. Proceedings of the VLDB Endowment (PVLDB), 2024, 17(8): 1900-1913.
- [12] HE K, ZHANG X, REN S, et al. Deep Residual Learning for Image Recognition[C/OL]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016: 770-778. DOI: 10.1109/CVPR.2016.90.
- [13] GUO D, YANG D, ZHANG H, et al. DeepSeek-R1: Incentivizing Reasoning Capabilities in LLMs via Reinforcement Learning[J/OL]. Nature, 2025, 645(8081): 633-638. DOI: 10.1038/s41586-025-09422-z.